Effet bélier

September 29, 2025

Les N brebis possèdent deux états: en chaleur (état noté 1 par la suite) et pas en chaleur (état noté 0 par la suite). Chaque brebis $i \in \{1, \dots, N\}$ passe de l'état 0 à l'état 1 au temps inconnu S^i (S pour les sssaleurs, il faut le dire avec un cheveux sur la langue).

Pour plus tard: ajouter un nouveau passage à l'état 0, il est trop tard bye bye la repro

Le but est de détecter si $S^i \leq T$ ou $S^i > T$ en fonction des données de reproduction. Le temps T représente ici, le jour final : le jour de l'IA (insémination artificiel).

Ces reproductions se font à des (inter) instants $\tau^i_1, \dots, \tau^i_{K^i}$ où K^i est le nombre de reproduction de la brebis i. La reproduction au temps τ^i_j dure un temps U^i_j. On note $T^i_j = \sum_{k=1}^{j} \tau^i_k$ les temps de repros.

On se base sur un modèle simple de Poisson composé avec ruptures. Cela signifie que pour chaque brebis, avant S^i les temps entre les reproduction se font à des temps exponentielles de paramètres λ_0, que les durées U^i_j sont aléatoires, on suppose qu'ils suivent une loi exponentielle de paramètre μ_0. Après S^i la situation est similaire mais avec comme paramètres λ_1 et μ_1.

A voir dans un second temps, mais on a des données où on a fait des IA et on sait si elle a fonctionné ou non. C'est-à-dire que dans mon jeu de données, j'ai pour chaque brebis i, v.a. Z^i qui vaut 1 si l'IA a marché et 0 sinon. On suppose que

$$Z^i \sim \mathcal{B}\left(p_0 \mathbf{1}_{S^i > T} + p_1 \mathbf{1}_{S^i \leq T}\right).$$

NB: j'avais parlé d'utiliser cette info pour calibrer les paramètres mais plusieurs questions se posent. D'abord, le but est de créer un algo qui trouve si $S^i < T$ ou non sans cette info. Deuxièmement il est possible que les 4 paramètres $\lambda_0, \dots$ sont années-dépendant via le côté libido du bélier dépendant.

NB dans l'idée

$$\lambda_1 > \lambda_0, \ \mu_1 > \mu_0, \ p_1 > p_0$$

1 Calcul de la log-vraisemblance

On pose $\lambda = (\lambda_0, \lambda_1), \mu = (\mu_0, \mu_1)$ et $S = (S^1, ..., S^N)$. La log-vraisemblance $L(\lambda, \mu, S)$ est donnée par

$$L(\lambda, \mu, S) = \prod_i \left(\frac{e^{-(\lambda_0 S^i)} (\lambda_0 S^i)^{n^i}}{n^i!} \mu_0^{n_i} e^{-\mu_0 \sum_{j=1}^{n^i} U_j} \right.$$
$$\left. \frac{e^{-\lambda_1 (T - S^i)} (\lambda_1 (T - S^i))^{K^i - n^i}}{(K^i - n^i)!} \mu_1^{K^i - n_i} e^{-\mu_1 \sum_{j=n^i+1}^{K^i} U_j} \right),$$

où K^i est le nombre total de sauts de l'individu i, et n^i dépend de S^i et compte le nombre de saut dans l'intervalle $[0, S^i]$. La log-vraisemblance associée:

$$\ell(\lambda,\mu,S) = \sum_i \Big((\lambda_1-\lambda_0)S^i - \lambda_1 T + n_i \log\left(\lambda_0\mu_0 S^i\right) + (K^i - n_i)\log\left(\lambda_1\mu_1(T-S^i)\right) \\ - \sum_{j=1}^{n^i} (\log(j) + \mu_0 U_j) - \sum_{j=n^i+1}^{K^i} \left(\log(j-n^i) + \mu_1 U_j\right) \Big).$$

Au vue de la combinatoire, il est impossible de l'optimiser directement sur (λ, μ, S). Cependant, il n'est pas difficile de l'optimiser à certains paramètres connus.

1.1 Optimisation à S fixé

En optimisant à S fixé, on trouve

$$\lambda_0 = \frac{\sum_i n^i}{\sum_i S^i} \qquad \lambda_1 = \frac{\sum_i K^i - n^i}{\sum_i (T - S^i)} \tag{1}$$
$$\mu_0 = \frac{\sum_i n^i}{\sum_i \sum_{j\le n^i} U_j^i}, \qquad \mu_1 = \frac{\sum_i (K^i - n^i)}{\sum_i \sum_{j>n^i} U_j^i}$$

1.2 Optimisation à (λ, μ) fixé

Commençons par un calcul élémentaire. J'introduis la fonction suivante sur $[\alpha, \beta]$, $\alpha, \beta \in [0, T]$, $\beta > \alpha$.

$$\varphi : s \mapsto (\lambda_1 - \lambda_0)s + n\log(s) + (K-n)\log(T-s).$$

On a

$$\varphi'(s) = (\lambda_1-\lambda_0) + \frac{nT - Ks}{s(T-s)} = 0 \Leftrightarrow (\lambda_1-\lambda_0)s^2 - (T(\lambda_1-\lambda_0)+K)s - nT = 0$$
$$s = \frac{(T(\lambda_1-\lambda_0)+K) + \sqrt{(T(\lambda_1-\lambda_0)+K)^2 + 4nT}}{2}$$

Rappelons que s est positif (et inférieur à T), c'est pour cela que j'ai au maximum un 0. On a donc que le maximum de la fonction φ est $s^\star(K, n, \alpha, \beta)$ défini par

- $s^\star(K,n,\alpha,\beta) = \alpha$ si $\frac{(T(\lambda_1-\lambda_0)+K)+\sqrt{(T(\lambda_1-\lambda_0)+K)^2+4nT}}{2} \le \alpha$
- $s^\star(K,n,\alpha,\beta) = \frac{(T(\lambda_1-\lambda_0)+K)+\sqrt{(T(\lambda_1-\lambda_0)+K)^2+4nT}}{2}$ si $\frac{(T(\lambda_1-\lambda_0)+K)+\sqrt{(T(\lambda_1-\lambda_0)+K)^2+4nT}}{2} \in [\alpha,\beta]$
- $s^\star(K,n,\alpha,\beta) = \beta$ si $\frac{(T(\lambda_1-\lambda_0)+K)+\sqrt{(T(\lambda_1-\lambda_0)+K)^2+4nT}}{2} \ge \beta$

Ce calcul élémentaire nous donne la procédure itérative pour trouver le maximum de vraisemblance. En effet, pour chaque individus i, on calcule

$$\max_{0\le j\le (K^i-1)} \varphi\left(s^\star(K^i, n^i, T_j^i, T_{j+1}^i)\right),$$

et son max est atteint pour un certain j, au point

$$S^i = s^\star(K^i, n^i, T^i_j, T^i_{j+1}) \tag{2}$$

ce qui a un coup de calcul de $\mathcal{O}(n)$ si n est le nombre de données (moins que la programmation dynamique)

1.3 Procédure d'estimation

On fait comme le DP-EM de l'article *A Segmentation/Clustering Model for the Analysis of Array CGH Data* de F. Picard, S. Robin E. Lebarbier, and J.-J. Daudin

On se fixe des $\lambda^0 = (\lambda^0_0, \lambda^0_1)$, $\mu^0 = (\mu^0_0, \mu^0_1)$ et des temps de ruptures $(S^{i,0})_i$ que l'on peut tirer soit via de facon aléatoires soit avec des algos de clustering soit autre...

Puis on procède comme suit: Pour $n \geq 0$

- On met à jour λ^{n+1}, μ^{n+1} à partir des formules (**??**) en utilisant pour temps de ruptures $(S^i)_i$ les $(S^{i,n})_i$.
- On met à jour $(S^{i,n+1})_i$ en utilisant les formules (**??**) en utilisant pour λ, μ les λ^{n+1}, μ^{n+1}

Changer l'ordre de la maj change t-il qqch? Faire les 2 et prendre le meilleur?

On montre facilement que, si cette suite converge, alors elle converge vers un maximum local de la vraisemblance.

2 Selection de modèle

Pour forcer à avoir 0 ruptures pour certains individus, on peut faire de la selection de modèle.

2.1 BIC classique

Dans le BIC classique, on pénalise la log vraisemblance ℓ par la pénalité pen donnée par

$$\text{pen} = \frac{k \log(n)}{2}$$

où k est le nombre de ruptures et n le nombre total de données. Comment le mettre en place ici ? Comme suit (proche de ce qu'on faisait avant)

On se fixe des $\lambda^0 = (\lambda^0_0, \lambda^0_1)$, $\mu^0 = (\mu^0_0, \mu^0_1)$ et des temps de ruptures $(S^{i,0})_i$ que l'on peut tirer soit via de facon aléatoires soit avec des algos de clustering soit autre...

Puis on procède comme suit: Pour $n \geq 0$

- On met à jour λ^{n+1}, μ^{n+1} à partir des formules (**??**) en utilisant pour temps de ruptures $(S^i)_i$ les $(S^{i,n})_i$.
- On met à jour $(S^{i,n+1})_i$ comme suit. En utilisant les formules (**??**) en utilisant pour λ, μ les λ^{n+1}, μ^{n+1}, on trouve des temps de ruptures temporaires $(S^{i,n+}{}_i$. On peut calculer des vraisemblances partielles (correspondantes aux vraisemblances des indiv i sans ou avec ruptures):

$$\ell^i_0 = -\lambda^{n+1}_0 T + K_i \log\left(\lambda_0 \mu^{n+1}_0 T\right) - \sum_{j=1}^{K^i} \left(\log(j) + \mu^{n+1}_0 U_j\right)$$

et (pour la deuxième j'ai pas réindexer mais j'espere que c'est compréhensible)

$$\ell_1^i = (\lambda_1 - \lambda_0)S^{i,n+} - \lambda_1 T + n_i \log\left(\lambda_0\mu_0 S^{i,n+}\right) + (K^i - n_i)\log\left(\lambda_1\mu_1(T - S^{i,n+})\right) - \sum_{j=1}^{n^i}(\log(j) + \mu_0 U_j) - \sum_{j=n^i+1}^{K^i}\left(\log(j - n^i) + \mu_1 U_j\right).$$

On a naturellement $\ell_1^i \geq \ell_0^i$; on les classes de tel façon que

$$\ell_1^{i_1} - \ell_0^{i_1} \geq \ell_1^{i_2} - \ell_0^{i_2} \geq .... \geq \ell_1^{i_N} - \ell_0^{i_N},$$

puis je calcule itérativement

$$\sum_i \ell_0^i - 0$$

$$\sum_{l=2}^{N} \ell_0^{i_l} + \ell^{i_1} - \frac{1\ln(n)}{2}$$

etc. jusqu'à

$$\sum_{l=1}^{N} \ell_1^{i_l} - \frac{N\ln(n)}{2}$$

je garde le plus grand, j'aurai donc les brebis qui ont une rupture ainsi que leurs temps de ruptures.

Maintenant chaque étape de mon algorithme me coute d'abord $\mathcal{O}(N)$ pour calculer mes ℓ et mes S puis encore un $\mathcal{O}(N)$ pour savoir qui je garde donc je reste en coût $\mathcal{O}(N)$. Quelque-soit en quoi on compte (brebis N ou nb de repro n) il ne me semble pas que l'on passe en n^2 ou N^2.

2.2 BIC modifié

On s'inspire de *Joint segmentation, calling, and normalization of multiple CGH profiles* de EMILIE LEBARBIER, MARK HOEBEKE, GUILLEM RIGAILL, BABA THIAM EQUIPPE et STÉPHANE ROBIN. Cette article se base sur *A Modified Bayes Information Criterion with Applications tothe Analysis of Comparative Genomic Hybridization Data* de Nancy R. Zhang et David O. Siegmund. Je lis ces deux papiers, et j'adapte. Les preuves du deuxième sont censé être dans une annexe en ligne mais je n'ai pas trouvé.

Par la suite, j'utilise des notations bayesiennes. On pose M_k le modèle où j'observe k ruptures; k varie donc entre 0 et N.

Avec la méthode BIC, on choisit le modèle en maximisant $p(M_i|y)$.

Je suppose que la probabilité *a priori* que le modèle soit le modèle k ne dépend pas de k:

$$p(M_k) = \frac{1}{N+1},$$

je suppose que les paramètres $\theta_k = (\lambda, \mu, S^{i_1}, ..., S^{i_k})$ sont tirés selon un prior $\pi(\theta_i|M_i)$. Ce dernier sera grosso-modo choisi comme une loi impropre égal à 1.

Avec ce choix de prior sur les modèles j'ai, D'après la formule de Bayes,

$$p(M_i|y) = \frac{p(y|M_i)P(M_i)}{p(y)},$$

où y sont mes données. J'ai donc que maximiser $p(M_i|y)$ est équivalent à maximiser $p(y|M_i)$. Or,

$$p(y|M_i) = \int p(y|\theta_i, M_i)\pi(\theta_i|M_i)d\theta_i = \int e^{Q_i(\theta_i)}d\theta_i,$$

avec

$$Q_i(\theta_i) = \log(p(y|\theta_i, M_i)\pi(\theta_i|M_i)).$$

Soit $\widetilde{\theta_i}$ un maximum de Q_i. Par la formule de Taylor, on a

$$Q_i(\theta_i) \approx Q_i(\widetilde{\theta_i}) - \frac{1}{2}(\theta_i - \widetilde{\theta_i})^t H(\theta_i - \widetilde{\theta_i}),$$

où H est la Hessienne de Q (fois -1 pour avoir une matrice positive, en effet comme on prend la Hessienne en un maximum, elle est définie négative). En calculant l'intégrale de cette approximation, on trouve que (cf. le doc de Bhat et Kumar *On the derivation of the Bayesian Information Criterion*)

$$\log(p(y|M_i)) = \log(p(y|\widetilde{\theta_i}, M_i)) + \frac{|\theta_i|}{2}\log(2\pi) - \frac{1}{2}\log(|H|)$$

Quelques questions: est-ce que j'inclus vraiment λ, μ dans les θ alors qu'ils sont inclus dans tous les modèles? Autre question, est-ce que j'ai $N+1$ modèle cad k ruptures avec $k \in \{0, ...N+1\}$ ou alors j'ai 2^N modèles consistant à avoir 0 ou 1 rupture pour chaque individu. Je commence à opter pour la seconde.

Je continu avec le second choix. L'indice du modèle u est dans $\{0,1\}^N$, $u_k = 0$ signifie que l'individu k n'a pas de ruptures et $u_k = 1$ une. On a donc

$$Q_u(\theta_u) = \sum_{i=1}^{N} \ell^i_{u_i}(\lambda, \mu, S^i)$$

avec

$$\ell^i_0(\lambda, \mu, S) = -\lambda_0 T + K_i \log(\lambda_0\mu_0 T) - \sum_{j=1}^{K^i}(\log(j) + \mu_0 U_j),$$

et

$$\begin{aligned}\ell^i_1(\lambda, \mu, S) = (\lambda_1 - \lambda_0)S^i - \lambda_1 T + n_i \log\left(\lambda_0\mu_0 S^i\right) + (K^i - n_i)\log\left(\lambda_1\mu_1(T - S^i)\right) \\ - \sum_{j=1}^{n^i}(\log(j) + \mu_0 U_j) - \sum_{j=n^i+1}^{K^i}\left(\log(j - n^i) + \mu_1 U_j\right).\end{aligned}$$

L'idée du BIC est que

$$H \sim nI,$$

où I est la matrice d'information de Fischer qui dépend du nombre de paramètres mais pas du nombre de données. Nous ici (j'omets les tildes sur les θ), quelle est la forme des dérivées partielles? J'en calcule certaines de formes différentes pour avoir une idée.

$$\partial_{S^a, S^b} Q_u(\theta_u) = \sum_{i=1}^{N} \partial_{S^a, S^b}\ell^i_{u_i}(\lambda, \mu, S^i)$$

et $\partial_{S^a,S^b}\ell^i_{u_i}(\lambda,\mu,S^i)\neq 0$ ssi $u_i=1$ et $a=b=i$. On n'a donc pas $H\sim NI$ car ici $\partial_{S^a,S^b}Q_u(\theta_u)=X_a\mathbf{1}_{a=b}$ où X_a est une v.a.

$$\partial_{S^a,\lambda_0}Q_u(\theta_u)=\sum_{i=1}^N\partial_{S^a,S^b}\ell^i_{u_i}(\lambda,\mu,S^i)$$

$$\partial_{\lambda_0,\mu}Q_u(\theta_u)=\sum_{i=1}^N\partial_{\lambda_0,\mu}\ell^i_{u_i}(\lambda,\mu,S^i)=0$$

En bref, $H=H^u$ est la forme

$$H=\begin{pmatrix} D_1 & 0 & 0 & 0 & -\mathbf{1}_{u_1=1} & -\mathbf{1}_{u_2=1} & \dots & -\mathbf{1}_{u_N=1}\\ 0 & D_2 & 0 & 0 & \mathbf{1}_{u_1=1} & -\mathbf{1}_{u_2=1} & \dots & \mathbf{1}_{u_N=1}\\ 0 & 0 & D_3 & 0 & 0 & 0 & \dots & 0\\ 0 & 0 & 0 & D_4 & 0 & 0 & \dots & 0\\ -\mathbf{1}_{u_1=1} & \mathbf{1}_{u_1=1} & 0 & 0 & X^1(\theta_1) & 0 & ... & 0\\ -\mathbf{1}_{u_1=1} & \mathbf{1}_{u_1=1} & 0 & 0 & 0 & X^2(\theta_1) & ... & 0\\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots\\ -\mathbf{1}_{u_1=1} & \mathbf{1}_{u_1=1} & 0 & 0 & 0 & 0 & ... & X^N(\theta_1) \end{pmatrix},$$

avec

$$D_1=(N-N(u))c_1(\theta)+N(u)c_2(\theta),\quad D_2=c_3(\theta)+N(u)c_4(\theta)$$
$$D_3=c_5(\theta)+N(u)c_6(\theta),D_3=c_7(\theta)+N(u)c_8(\theta)$$

où j'ai rangé comme suit $\theta=(\lambda_0,\lambda_1,\mu_0,\mu_1,S^1,...,S^N)$ et c_k désignent des constantes déterministes, $N(u)=\sum_k\mathbf{1}_{u_k=1}$ (on se place dans un regime $N(u)$ grand), les X^i sont des v.a..J'ai des pbs de regularité car les n_i dépendent des données et des S^i, ma densité n'est pas "reguilire" fiasons comme-ci car c'est sur un nb de point de mesure nulle On a

$$X^i(\theta)=\mathbf{1}_{u_i=1}\left(-\frac{n_i}{S_1^2}+\frac{K^i-n^i}{(T-S^i)^2}\right).$$

(nb j'ai peut-être moins ça) Les constantes c_k viennent de l'utilisation de la LGN. Il faut maintenant avoir une idée de l'ordre (en $N,N(u)$) de

$$\log(\det(H)).$$

On a

$$\log(\det(H))=\sum_{i=1}^4\log\left((N-N(u))c_{2i-1}+N(u)c_{2i}\right)+\sum_{i=1}^N\log\left(X^i(\theta_u)\right)$$

Ca me semble un peu compliqué. Peut-être que $\sum_{i=1}^N\log\left(X^i(\theta_u)\right)\approx N(u)$.