Tests multiples et FDR

February 17, 2023

Je reprend ici l'approche et les résultats de () avec la démonstration de (Benjamini, Yekutieli) qui peut s'étendre à la fin à des cas de dépendances.

J'ai m tests avec des hypothèses H_j^i avec $i \in \{0,1\}$ et $j \in [\![1,m]\!]$

Le but est de trouver lesquelles des H_j^0 sont vraies, on va donc poser m_0 le nombre d'hypothèses qui sont effectivement vraies (et que donc $m_1 = m - m_0$ hypothèses sont fausses). On va considérer que ce sont les m_0 premières.

Cette procédure est lié au $p-$ values. Pour chaque $j \in [\![1,m]\!]$, j'introduit la $p-$value (voir Section 2 plus bas) associée au test j, noté P_j.

1 Procédure de Benjamini-Hichberg

On ordonne les $p-$values $P_{(1)} \leq ... \leq P_{(m)}$; on pose

$$k = \max\{i \mid P_{(i)} \leq q_i = \frac{i}{m}q\}$$

où q est un seuil que je me fixe. Alors je rejette $H^0_{(1)}, ..., H^0_{(k)}$ et pas les autres. Si aucun $P_{(i)} > q_i = \frac{i}{m}q$ pour tout i, je n'en rejette évidemment aucun.

La particularité de cette procèdure est qu'elle controle le *false discovery rate* (FDR) qui est la proportion moyenne d'erreur parmi les hypothèses rejeté.

Mathématiquement, si on suppose que les données sont aléatoires alors les $p-$values sont des vairables aléatoires et je peux introduire les autres v.a. suivantes: V le nombre d'hypothèses nulles vraies rejetés, et R le nombre d'hypothèse rejeté et $Q = V/R$ leur quotient (inobservable/incalculable). Le FDR est défini par

$$\text{FDR} = \mathbb{E}[Q] = \mathbb{E}\left[\frac{V}{R}\right]$$

Le résultat de Benjamini-Hichberg donne que la procédure précédente garantit que le FDR est inférieur à qm_0/m et donc inférieur à q dans tous les cas lorsque les tests sont indépendants.

1.1 Démonstration

Soit $A_{v,s}$ l'évènement $\{V = v, R = v + s\}$ alors on a simplement

$$\text{FDR} = \sum_{s=0}^{m_1}\sum_{v=0}^{m_0} \frac{v}{v+s}\mathbb{P}(A_{v,s}). \tag{1}$$

Step 1 : expression pour $\mathbb{P}(A_{v,s})$

Fixons momentanément v, s. Pour un sous ensemble $\Omega \subset [\![1, m_0]\!]$ de taille v, je considère $A^{\Omega}_{v,s} \subset A_{v,s}$ l'évènement "les v hypothèses vraies rejetées sont celles décrite par Ω".

Pour $i \leq m_0$, si $i \in \Omega$ et $A^{\Omega}_{v,s}$ est vraie alors, comme elle a été rejetée et que l'on en a rejeté $v+s$ alors on a $P_i \leq P_{(v+s)} \leq q_{v+s}$, si c'est plus grand elle n'a pas été rejetée; d'où

$$\mathbb{P}\left(P_i \leq q_{v+s}, A^{\Omega}_{v,s}\right) = \mathbf{1}_{i\in\Omega}\mathbb{P}(A^{\Omega}_{v,s}).$$

En conséquence,

$$\begin{aligned}\sum_{i=1}^{m_0} \mathbb{P}\left(P_i \leq q_{v+s}, A_{v,s}\right) &= \sum_{i=1}^{m_0} \sum_{\Omega\subset[\![1,m_0]\!]} \mathbb{P}\left(P_i \leq q_{v+s}, A^{\Omega}_{v,s}\right) \\ &= \sum_{\Omega\subset[\![1,m_0]\!]} \sum_{i=1}^{m_0} \mathbf{1}_{i\in\Omega}\mathbb{P}(A^{\Omega}_{v,s}) \\ &= \sum_{\Omega\subset[\![1,m_0]\!]} v\mathbb{P}(A^{\Omega}_{v,s}) = v\mathbb{P}\left(A_{v,s}\right)\end{aligned}$$

et donc

$$\mathbb{P}\left(A_{v,s}\right) = \frac{1}{v}\sum_{i=1}^{m_0} \mathbb{P}\left(P_i \leq q_{v+s}, A_{v,s}\right)$$

et par (1)

$$\mathrm{FDR} = \sum_{s=0}^{m_1}\sum_{v=0}^{m_0} \frac{1}{v+s}\sum_{i=1}^{m_0} \mathbb{P}\left(P_i \leq q_{v+s}, A_{v,s}\right).$$

Step 2: une expression de la FDR sans v, s mais en somme sur $r = v + s$

Je fixe encore v, s et $i \leq m_0$.

Je note $C^{(i)}_{v,s}$ l'événement "Si H^0_i est rejeté alors $v-1$ vraies hypothèses nulles et s hypothèses nulles fausses sont aussi rejeté avec lui". Donc par définition

$$\{P_i \leq q_{v+s}\} \cap A_{v,s} = \{P_i \leq q_{v+s}\} \cap C^{(i)}_{v,s},$$

On introduit maintenant $C^{(i)}_r = \cup_{v+s=r} C^{(i)}_{v,s}$ (l'evt si i est rejeté alors on en a $r-1$ autres aussi rejetés). Comme cette union est disjointe alors

$$\begin{aligned}\mathrm{FDR} &= \sum_{i=1}^{m_0}\sum_{s=0}^{m_1}\sum_{v=0}^{m_0} \frac{1}{v+s}\mathbb{P}\left(P_i \leq q_{v+s}, C^{(i)}_{v,s}\right) \\ &= \sum_{i=1}^{m_0}\sum_{r=0}^{m} \sum_{v,s,v+s=r} \frac{1}{r}\mathbb{P}\left(P_i \leq q_r, C^{(i)}_{v,s}\right) \\ &= \sum_{i=1}^{m_0}\sum_{r=0}^{m} \frac{1}{r}\mathbb{P}\left(P_i \leq q_r, C^{(i)}_{r}\right)\end{aligned}$$

Step 3: fin On a, par indépendance,

$$\mathbb{P}\left(P_i \leq q_{v+s}, C^{(i)}_r\right) = \mathbb{P}\left(P_i \leq q_r\right)\mathbb{P}\left(C^{(i)}_r\right)$$

Comme, sous H_0, P_i suit une loi uniforme (dans le cas continue, sinon on a toujours une l'inégalité) alors

$$\mathbb{P}\left(P_i \leq q_r\right) = q_r = \frac{r}{m}q.$$

De plus

$$\sum_{r=1}^{m} \mathbb{P}\left(C_r^{(i)}\right) = \mathbb{P}(\cup_{r=1}^{m} C_r^{(i)}) = 1$$

donc

$$\mathbb{P}\left(P_i \leq q_{v+s}, C_r^{(i)}\right) = \mathbb{P}\left(P_i \leq q_r\right) \mathbb{P}\left(C_r^{(i)}\right) = \frac{m_0}{m} q$$

2 Rappel $p-$value

On peut toujours écrire le test d'une hypothèse $H_0 = \{\theta \in \Theta_{\theta_0}\}$ sous la forme qu'une statistique $T(x)$ de mes données x n'est pas dans une région de rejet R_α qui dépend d'une erreur de première espèce que je veux contrôler. Je veux dire que si ma statistique $T(x)$ est dans ma zone de rejet alors je rejette H_0.

La $p-$value se définie comme

$$p = \sup\{\alpha \mid T(x) \in R_\alpha\}$$

D'un point de vue pratique, la zone de rejet est souvent de la forme $\{u|u > c\}$ (i.e On test si $T(x) > c$) et dans ce cas, je peux définir la $p-$value par

$$p = \sup_{\theta \in \Theta_{\theta_0}} \mathbb{P}\left(T(X) \geq T(x)\right)$$

Dans le cas où la statistique de test est continue, on peut montrer que si H_0 est vraie alors $p \sim \mathcal{U}[0,1]$ sinon elle est plus concentré en 0. En pratique

- si $p < 0.01$ alors très forte evidence contre H_0
- si $p < 0.05$ alors forte evidence contre H_0
- si $p < 0.1$ alors faible evidence contre H_0
- si $p > 0.1$ alors aucune evidence contre H_0

Attention, il ne faut pas l'interpréter comme $\mathbb{P}(H_0 \mid x)$; elle peut être élevé alors que H_0 est faux.